NYC 311

Exploración, benchmarking y propuesta analítica

PROYECTO INTEGRADOR · FASE 1

Decisión ejecutiva

Se reemplaza el caso sintético de El Monte por 13.072.334 solicitudes reales de NYC 311 (2021–2024). El conjunto supera el mínimo de 10 millones, posee dimensión temporal y territorial, y permite continuidad hacia ML distribuido y streaming. La pregunta es: ¿qué solicitudes presentan riesgo temprano de una atención prolongada respecto de su tipo de reclamo?

Resultado	Evidencia
Escala	13.072.334 filas; 3,5 GB de CSV crudo seleccionado
Grano	Una solicitud por unique_key; 100% de unicidad
Aptitud	98,60% con cierre; 98,29% con georreferencia
Restricción SLA	due_date solo 0,37%; no sirve como etiqueta global
Motor recomendado	Spark para el pipeline; DuckDB como verificador local

Corte de extracción: 11 de septiembre de 2026. El dataset oficial se actualiza diariamente; esta entrega queda fijada por sus archivos locales y conteos de control.

1. Problema, fuente y diseño analítico

Pregunta y uso de negocio

NYC 311 centraliza solicitudes no urgentes y las deriva a las agencias responsables. Una alerta temprana de atención prolongada permitiría priorizar casos, anticipar acumulación y distribuir capacidad. No se interpreta como causalidad ni reemplaza reglas operativas de las agencias.

Fuente y selección temporal

Fuente pública oficial: “311 Service Requests from 2020 to Present” (ID erm2-nwe9), descargada mediante la API de NYC Open Data. Se utilizan 2021–2024: se excluye 2020 por su carácter extraordinario durante COVID-19 y se evitan 2025–2026 para mantener una ventana cerrada y una evaluación temporal limpia.

Año	Solicitudes	% cerradas	Mediana resolución (h)
2021	3.220.882	99.02	13.4
2022	3.169.960	99.20	7.3
2023	3.224.723	98.08	7.9
2024	3.456.769	98.16	8.1

Variable objetivo para Fase 2

Para cada complaint_type se aprenderá en 2021–2023 el percentil 75 de resolution_hours. Una solicitud cerrada será “prolongada” si supera ese umbral. El test será 2024. Esta etiqueta se adapta a la heterogeneidad entre reclamos y evita el due_date casi vacío. Closed date, status, resolution description y fechas de actualización se usan solo para construir/auditar la etiqueta, nunca como predictores al ingreso.

Privacidad y uso

La publicación oficial indica que no incluye información identificable del cliente. Aun así, coordenadas y descriptores pueden elevar riesgo de reidentificación contextual; se recomienda minimizar precisión geográfica en productos Gold y controlar acceso. Fuente y condiciones: NYC Open Data, dataset erm2-nwe9.

2. EDA a escala y calidad

Control	Resultado	Implicación
Llaves	13.072.334	Sin duplicados en unique_key
Fecha creación	0	Cobertura completa
Cierre	98.60%	Etiqueta disponible en gran mayoría
Due date	0.37%	Descartado como objetivo global
Geografía	98.29%	Útil con minimización
Duración negativa	26.113	Excluir de etiqueta; conservar evidencia

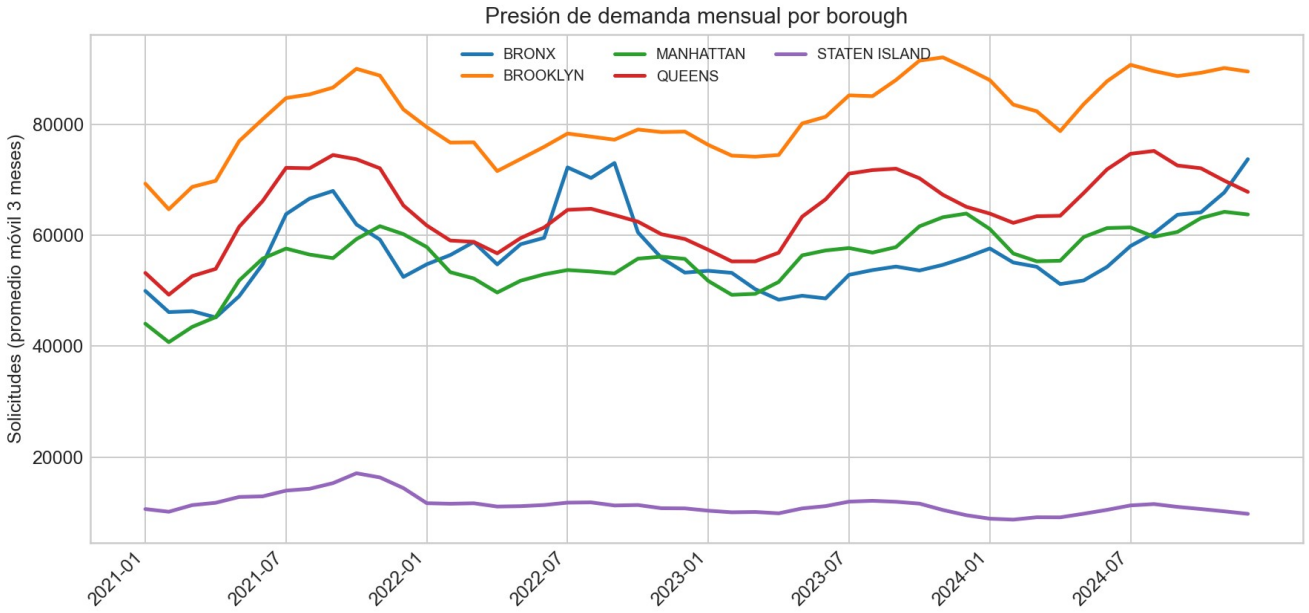


Figura 1. Promedio móvil de tres meses por borough. La ventana suaviza ruido y el dense_rank mensual identifica presión relativa. Brooklyn y Queens concentran los mayores volúmenes, pero el resultado describe demanda registrada, no necesidad social total.

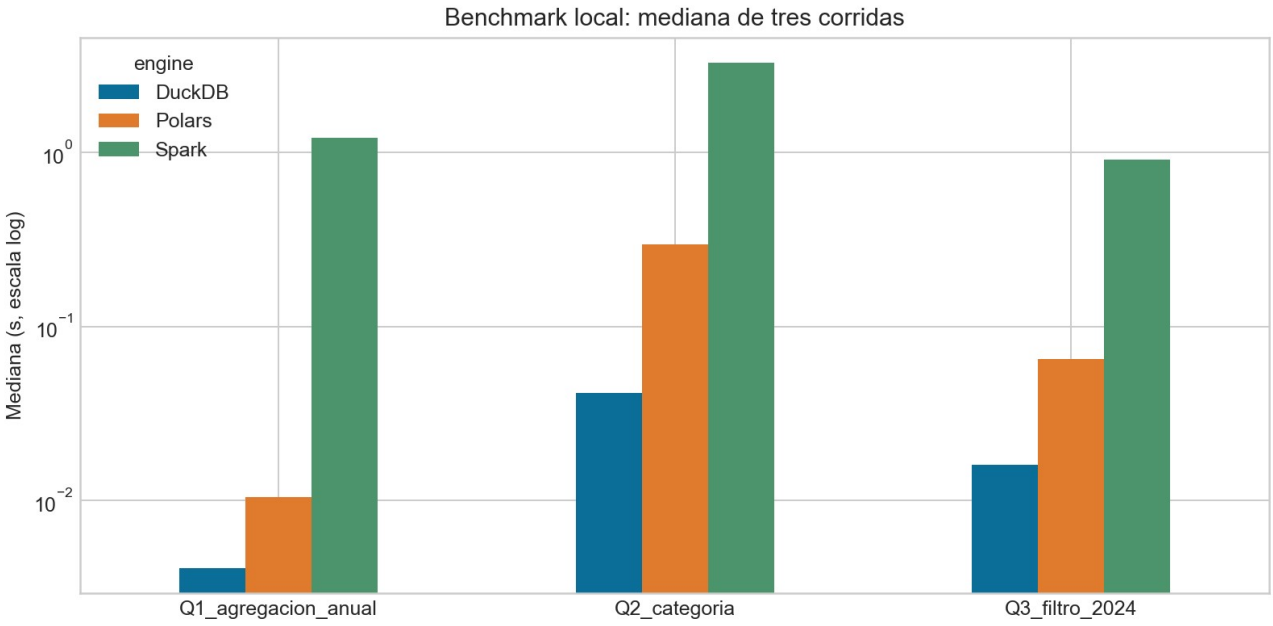
Concentración temática

Tipo de reclamo	Solicitudes	Participación	Mediana h
Illegal Parking	1.706.462	13.05%	1.0
Noise - Residential	1.417.088	10.84%	0.8
HEAT/HOT WATER	958.267	7.33%	43.2
Noise - Street/Sidewalk	648.077	4.96%	0.6
Blocked Driveway	645.119	4.93%	1.2
UNSANITARY CONDITION	425.946	3.26%	266.3

Los dos reclamos principales explican 23,89% del total. Las medianas difieren fuertemente entre categorías; por eso un único umbral global de demora produciría una etiqueta sesgada hacia procesos naturalmente más lentos.

3. Benchmark y planes de ejecución

Tres consultas propias se ejecutaron sobre el mismo Parquet: agregación anual, top de categorías y filtro 2024. Cada motor recibió una corrida de calentamiento y tres corridas medidas; se reporta la mediana. Se validaron los conteos anuales entre los tres motores.



Consulta	Spark (s)	DuckDB (s)	Polars (s)
Q1 agregacion anual	1.213	0.004	0.010
Q2 categoria	3.286	0.041	0.295
Q3 filtro 2024	0.911	0.016	0.065

Lectura crítica

DuckDB fue el más rápido localmente (0,004–0,041 s), seguido por Polars (0,010–0,295 s); Spark tardó 0,911–3,286 s por su costo de coordinación. No significa que DuckDB escale mejor: el ensayo cabe en un Mac y favorece motores embebidos. Spark muestra poda de columnas en ReadSchema, poda de partición para created_year=2024 y Exchange hashpartitioning en agregaciones; este shuffle es el costo distribuido esperado. Los planes completos se adjuntan como evidencia.

Limitación: los tiempos reflejan este hardware, archivos ya convertidos y caché del sistema operativo. No se comparan costos de clúster ni concurrencia multiusuario; se evita extrapolar aceleraciones lineales.

4. Motor, arquitectura y costo

Recomendación

Usar Spark como motor principal del proyecto acumulativo. Su sobrecosto local se justifica porque las fases siguientes exigen preparación distribuida, MLlib, MLflow y Structured Streaming. DuckDB queda como control independiente para consultas y pruebas rápidas; Polars es una alternativa eficiente para prototipos en memoria.

Capa	Contenido	Control principal
Bronze	CSV oficiales inmutables + metadatos de extracción	Conteo, tamaño, fecha, URL y checksum
Silver	Parquet tipado, particionado por año; timestamps y duración	Llave única, fechas, cobertura y anomalías
Gold	Features al ingreso, umbrales por reclamo y etiqueta	Sin fuga; split temporal 2021–2023 / 2024
Streaming	Replay de created_ts hacia Kafka	Watermark, ventanas y eventos tardíos

Costo paramétrico

Desarrollo local: costo incremental de infraestructura ≈ USD 0. En nube, una corrida ocasional de 1–2 horas con 2–4 workers pequeños se estima en USD 1–5, más almacenamiento y transferencia. La cifra es un rango de planificación, no una cotización: proveedor, región, descuentos y autoscaling pueden cambiarla. En Fase 2 se registrarán duración, horas-worker y bytes leídos para sustituir el rango por costo observado.

Decisión FinOps	Regla
Formato	Parquet comprimido y lectura columnar
Partición	Año en Silver; mes solo si la poda compensa archivos pequeños
Escalamiento	Aumentar workers solo si la reducción de tiempo supera el costo
Persistencia	Cachear únicamente datasets reutilizados; liberar al terminar

Continuidad

Fase 2 entrenará un clasificador interpretable y modelos de referencia con seguimiento en MLflow. Fase 3 reproducirá las solicitudes por created_ts, agregará demanda en ventanas con watermark y evaluará calidad, disparidad territorial y gobernanza.

5. Conclusiones, límites y reproducibilidad

Conclusiones

1) NYC 311 cumple la escala y aporta evidencia real para un problema operativo defendible. 2) La cobertura de due_date invalida una etiqueta SLA universal; el umbral relativo por tipo de reclamo es más honesto. 3) La demanda y la latencia son heterogéneas, por lo que categoría, agencia, canal, tiempo y territorio deben evaluarse con cuidado. 4) DuckDB domina el EDA local, pero Spark reduce el riesgo de reescritura al continuar hacia ML y streaming.

Riesgos y sesgos

Las solicitudes reflejan propensión y acceso para reportar, no toda la necesidad ciudadana. Diferencias territoriales pueden mezclar demanda, canales, capacidad institucional y composición de reclamos. El modelo no deberá usar atributos posteriores al ingreso ni convertir borough o geografía en sustitutos acríticos de vulnerabilidad. Se reportarán desempeño y tasas de alerta por territorio, agencia, canal y categorías de volumen suficiente.

Reproducibilidad

Artefacto	Propósito
Fase_1_EDA_Benchmark_NYC311.ipynb	Ingesta, controles, EDA, ventanas, benchmark y planes
data/raw/nyc311_2021…2024.csv	Capa Bronze fijada al corte
data/silver/nyc311_v3/	Parquet analítico particionado
evidencia/	CSV, JSON y planes físicos auditables
outputs_fase1/	Figuras generadas por el notebook

Validación del uso de IA

Se empleó IA generativa para estructurar el notebook, proponer consultas y redactar el borrador. La validación incluyó: conteos oficiales por año; aserción de unicidad; ejecución completa; comparación semántica entre motores; inspección de planes; y revisión crítica de formato de fechas, cobertura SLA, fuga de información y extrapolación de costos. Los dos errores detectados durante la construcción —formato ISO y lectura de particiones— fueron corregidos y revalidados.

Fuentes

NYC 311, “About NYC 311”: https://portal.311.nyc.gov/about-nyc-311/
NYC Open Data, 311 Service Requests from 2020 to Present: https://data.cityofnewyork.us/d/erm2-nwe9
Metadatos y diccionario API: https://data.cityofnewyork.us/api/views/erm2-nwe9
311 Service Level Agreements: https://data.cityofnewyork.us/d/cs9t-e3x8