NYC311 Fase 2

Pipeline distribuido y riesgo de atención prolongada al ingreso

Magíster en Data Science UDD | Profesor Luis Castillo

Decisión y alcance

Se seleccionó E3_3 por el área precisión-recall media en los cortes de validación 2022 y 2023, con la regla de alerta fijada en 0,2 antes de evaluar 2024. El ajuste final utilizó 9.189.270 solicitudes históricas etiquetables y la evaluación incluyó 3.365.506 solicitudes de 2024.

La pregunta es qué solicitudes tienen, al ingresar, mayor riesgo de superar el percentil 75 histórico de duración de su tipo. La unidad es unique_key. Esta definición no representa incumplimiento de un SLA oficial. Los tipos sin historia suficiente reciben abstención de etiqueta y de alerta operativa.

Resultado de prueba 2024	Valor observado
Área PR / ROC	0,409 / 0,617
Precisión / recall / F1	0,303 / 0,845 / 0,446
Prevalencia / solicitudes alertadas	28,46% / 79,27%
Ajuste / inferencia materializada	2115,9 s / 10,4 s

El ajuste final utilizó el 100,00% de la historia etiquetable. Tras dos intentos interrumpidos por espacio en disco y un ajuste provisional del 5%, se liberó almacenamiento y se completó el 100%. Se conserva la evidencia de los intentos anteriores.

El modelo detecta 84,49% de los casos prolongados, alerta 79,27% de las solicitudes y logra precisión 30,33%. La carga de alertas requiere acordar capacidad y validar utilidad antes de automatizar una priorización operativa.

Como referencia analítica, alertar a todas las solicitudes produciría F1 0,443 con 100% de alertas. Esta referencia contextualiza F1 y carga; no intervino en la selección.

La selección se desarrolló con una muestra determinista del 0,2%, mientras los umbrales históricos se estimaron sobre toda la historia elegible de cada corte. El desempeño solo describe solicitudes con cierre observado y umbral histórico válido; no representa todos los ingresos.

Se recuperó la ejecución tras resolver la expulsión automática de archivos por iCloud. Se usaron copias temporales verificadas con SHA256, sin modificar los CSV ni entregables de fase 1. El entorno también se ejecutó fuera de iCloud. Las cifras de modelos proceden de mlflow.search_runs() y sus tablas exportadas.

Preparación y calidad de datos

Bronze conserva referencias a los originales y sus hashes. Silver reconstruye tipos desde CSV, valida encabezados, fechas, rangos, nulos, blancos, cardinalidades y duplicados. Gold base solo incorpora variables deterministas; las etiquetas y umbrales se asignan por corte. Codificación y StandardScaler se ajustan dentro de Pipeline. No se imputan cierres ni duraciones y las demoras positivas extremas se conservan.

Control sobre cuatro años	Resultado
Solicitudes	13.072.334
Llaves distintas	13.072.334
Con cierre	12.889.965
Duraciones negativas	25.428
Con due_date	48.161

Se reconstruye Silver desde los CSV para auditar parseo y fijar America/New_York. Se reutilizan de fase 1 el contrato, las columnas y la definición de duración; su Silver no se sobrescribe. El modo alternativo de reutilización literal queda disponible, con la limitación de que fase 1 no fijó explícitamente su zona horaria. Las horas ambiguas por cambio estacional siguen limitadas por la ausencia de offsets en origen.

La diferencia frente a fase 1 fue auditada: la fórmula con America/Santiago reproduce 26.113 negativos, mientras America/New_York produce 25.428. Hay 685 casos negativos bajo Santiago y no negativos bajo Nueva York, sin cambios inversos. En total, 1.029.895 duraciones difieren entre ambas zonas; no se fuerza una coincidencia artificial con el antecedente. La conciliación y ejemplos quedan exportados.

Las razones de exclusión son mutuamente excluyentes: llave faltante, llave duplicada, creación inválida, año fuera del alcance, cierre inválido, solicitud abierta y duración negativa. Gold base retiene todas las razones. Los cierres posteriores a la fecha de observación se excluyen del etiquetado en cada corte; no se convierten en negativos.

El perfil por columna, conteos por año, rangos y conciliaciones se exportan como JSON y CSV. Las cardinalidades generales son aproximadas; la unicidad de unique_key se verifica con conteo exacto. Esta distinción evita interpretar error de estimación como duplicación.

Etiqueta temporal y variables

Entrenamiento	Evaluación	Cierre train anterior a
2021	2022	2022-01-01
2021 y 2022	2023	2023-01-01
2021 a 2023	2024 final	2024-01-01

Las etiquetas de ambos conjuntos de validación deben estar disponibles antes de 2024-01-01. La prueba se observa antes de 2026-09-11 00:00 Nueva York, una aproximación conservadora al día de descarga documentado. No se dispone de una extracción bitemporal que certifique cada estado histórico.

Cada p75 se calcula solo con cierres del entrenamiento disponibles antes del corte. Se usa percentile_approx con precisión 10.000 y un mínimo de 100 observaciones por tipo. Tipos nuevos, raros o faltantes conservan etiqueta nula; no se sustituye silenciosamente por un umbral global. Se reportan separadamente casos abiertos, cierres tardíos, tipos sin umbral y filas finalmente utilizadas.

Corte	Train utilizado	Evaluación	Sin umbral antes de muestrear
2022	5.931	6.154	10.093
2023	12.051	5.964	27.271
2024 final	9.189.270	3.365.506	26.799

Predictores: tipo de reclamo, canal, borough, tipo de ubicación y seno/coseno de hora, día semanal y mes. Faltantes categóricos usan un marcador explícito y categorías nuevas se conservan. No se imputa numéricamente porque las variables temporales provienen de creaciones válidas.

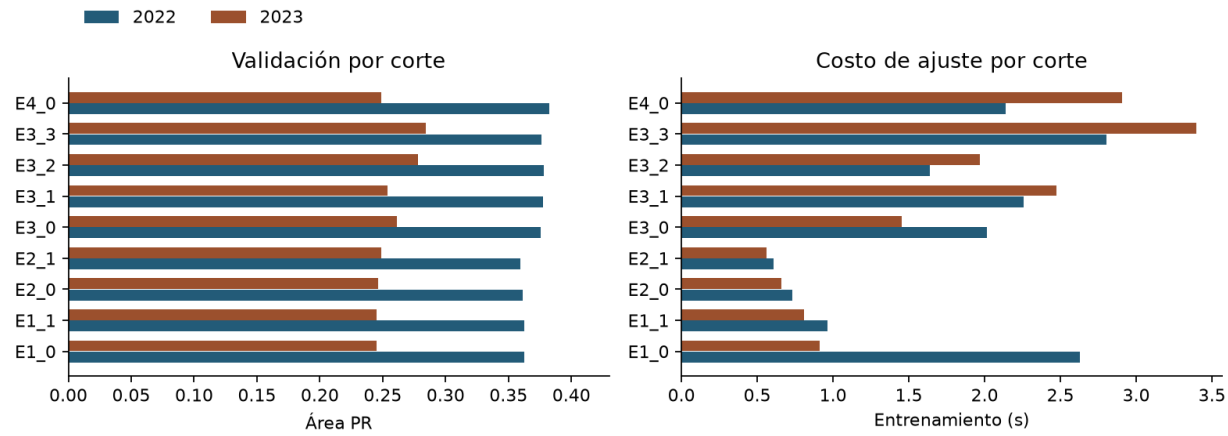
Se excluyen agencia por posibles reasignaciones; identificador, cierre, duración, status, resolución y actualizaciones por disponibilidad; y coordenadas precisas por minimización geográfica. Descriptor solo se usa en E4. Tipo, ubicación y descriptor pueden corregirse: ningún experimento reconstruye perfectamente lo conocido al ingreso. Evaluar solo cerrados introduce sesgo de selección.

Experimentos y selección

E1: logística L2 base regParam 0,01 y candidato 0,03. E2: mayor regularización 0,1 y 0,3. E3: GBT maxDepth {3,5} por maxIter {10,20}. E4: misma configuración estructurada de E1 base, añadiendo MiniLM. Son nueve candidatos y dos cortes, construidos con ParamGridBuilder. El bucle temporal evita mezclar pasado y futuro, siguiendo ADBD4 y Lab4.

Candidato	PR media	ROC media	Fit medio s
E1_0	0,304	0,574	1,8
E1_1	0,304	0,573	0,9
E2_0	0,304	0,572	0,7
E2_1	0,304	0,572	0,6
E3_0	0,318	0,585	1,7
E3_1	0,316	0,585	2,4
E3_2	0,328	0,599	1,8
E3_3	0,330	0,599	3,1
E4_0	0,316	0,583	2,5

Se selecciona PR media con igual peso por año y desempate por menor tiempo. La referencia trivial nunca alerta; su F1 es cero y la prevalencia contextualiza la referencia PR aleatoria. El umbral entre 0,1 y 0,9 maximiza F1 medio de validación y, ante empate, reduce alertas. Es un escenario analítico, no una capacidad operativa acordada.



Los escenarios completos de precisión, recall y carga de alertas están exportados. No se usó 2024 para elegir variables, hiperparámetros, familia ni umbral. La muestra limita la estabilidad de la selección, especialmente en categorías pequeñas; no se estimaron intervalos de incertidumbre.

Embeddings y evaluación final

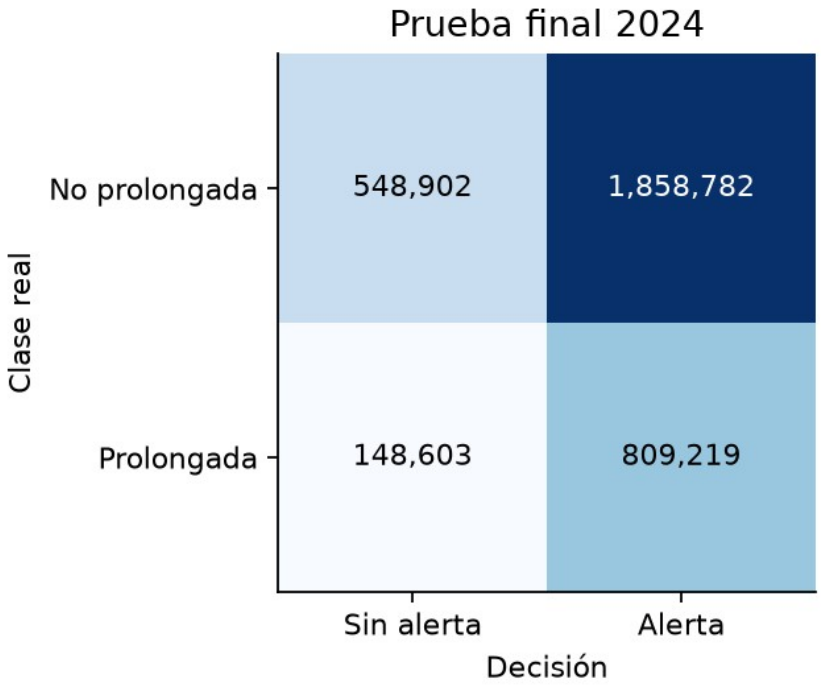
La hipótesis del Lab 5 es que tipo y descriptor aportan señal semántica adicional. Se usa all-MiniLM-L6-v2 congelado, revisión 1110a243fdf4706b3f48f1d95db1a4f5529b4d41, 384 dimensiones y normalización L2. El diccionario codifica cada texto distinto una vez; mapInPandas carga una copia por partición y procesa lotes 32. Se limita a una partición de embeddings por memoria.

Corte	PR E1 base	PR E4	Diferencia E4 menos E1
2022	0,363	0,382	0,020
2023	0,245	0,249	0,004

La diferencia media observada fue 0,012 puntos de área PR. La representación textual agregó señal en la media de validación; ello no prueba causalidad ni elimina el riesgo de atributos corregidos.

Generación/reutilización del diccionario por corte: 2023 = 1,5 s; fit E4 2,9 s; 2022 = 35,2 s; fit E4 2,1 s. Son costos incrementales de la caché, no dos codificaciones completas independientes.

Se verifican filas antes/después del join, persistencia del pipeline y regeneración textual dentro de tolerancia 1e-6. Los textos nuevos pueden representarse con la misma revisión; un tipo nuevo sigue sin tener etiqueta histórica. Los casos con descriptores no vistos tienen un artefacto separado por run. El costo de generar embeddings se registra aparte del clasificador.



El umbral congelado fue 0,2. La matriz utiliza 3.365.506 casos de prueba. El CSV de segmentos informa precisión, recall, F1 y fracción alertada por borough, canal y tipo para grupos con al menos 100 observaciones, conservando el volumen de los grupos menores. Las diferencias descriptivas no son evidencia causal de equidad.

Costo computacional y trazabilidad

Ejecución local en Mac arm64 con 8 núcleos y 8 GB de RAM: Spark local[2], driver 2 GB y cuatro particiones SQL. El ajuste final reparte train en 64 particiones y comprime RDD para limitar presión de memoria. El benchmark mantiene E1 fijo, usa dos muestras por hash, calentamiento y tres repeticiones por tamaño. La inferencia se fuerza sumando score; transform() solo no mide ejecución. Caché DISK_ONLY materializada; caché del sistema operativo no controlada.

Filas	Fit mediana s	Fit mínimo a máximo s	Inferencia mediana s
2.979	1,05	1,00 a 1,25	0,22
5.931	0,95	0,93 a 1,06	0,19

Preparar los 13.072.334 registros requirió 253,7 s. En el ajuste final completo, el monitor cada dos segundos registró un máximo de 2,17 GiB de RSS sumado de procesos; no equivale a memoria física exclusiva.

El tamaño mayor no tuvo una mediana más alta en este benchmark pequeño; no se infiere una ley de escalamiento ni una aceleración por aumentar filas. Los tiempos muestran el comportamiento de este equipo y no prueban escalabilidad entre máquinas. No se midió un segundo nivel de paralelismo ni se contrataron recursos cloud. Se registra RSS puntual de Python y procesos descendientes; la memoria configurada no equivale a consumo ni a un pico distribuido exhaustivo.

MLflow separa preparación, familia/candidato/corte, referencia trivial, benchmark y ajuste final. Guarda identidad de datos, versiones, semillas, parámetros efectivos, conteos, calidad, umbrales, modelos y recursos E4. La comparación sale de search_runs; la recarga contrasta probabilidades de 128 solicitudes fijas. Los tests artificiales previos permanecen separados de los resultados de negocio.

Discrepancia del benchmark de fase 1

Spark mediana s	PDF previo	Notebook y CSV
Q1 anual	1,213	1,388
Q2 categoría	3,286	1,984
Q3 filtro 2024	0,911	0,738

El CSV conserva tres corridas y coincide con el notebook redondeado. Los horarios del PDF (20:47) y notebook (20:54) son compatibles con una ejecución posterior, pero no prueban la causa. No se sobrescribe fase 1 ni se mezclan cifras de versiones. La reconciliación conserva también DuckDB y Polars.

Límites reproducción y uso de IA

La prueba 2024 ya se había observado con el modelo provisional del 5%. El reintento al 100% conservó la familia, hiperparámetros y umbral fijados antes de esa observación; no se volvió a hacer tuning ni se eligió entre ambos resultados de prueba. No se presenta como una prueba observada una sola vez.

La recomendación analítica se limita a E3_3 bajo el protocolo y la muestra de desarrollo utilizados. La prueba final no debe volver a utilizarse para ajustar esa decisión. Para una operación real falta acordar capacidad de atención, revisar calibración, monitorear deriva, validar atributos de ingreso con versiones y analizar solicitudes aún abiertas.

Los límites principales son selección de casos cerrados, observación aproximada del snapshot, correcciones posteriores de atributos, escasa historia para tipos raros, incertidumbre no cuantificada del muestreo y ejecución en un único equipo. Las áreas PR se aproximan con 1.000 bins en Spark; no se confunden con average precision de otra librería.

README describe el entorno fijado y las etapas prepare, tune, benchmark y final. El notebook muestra los resultados guardados y permite relanzar el pipeline con una bandera explícita. Gold reutilizable no contiene parámetros aprendidos en validación. predict.py utiliza el modelo final y se abstiene de alertar tipos sin umbral. relocate_mlflow.py adapta las rutas de artefactos si la carpeta se mueve.

Se preservan modelos, diccionario, encoder congelado y hashes. Las capas grandes se conservan en run_complete de la carpeta de entrega y pueden reconstruirse desde los cuatro CSV; el ZIP de entrega no necesita duplicar los crudos. El entorno y las copias temporales se mantuvieron fuera de iCloud para evitar expulsiones mientras se ejecutaba Spark.

Declaración de uso de IA

Se utilizó IA para revisar fuentes, diseñar temporalidad, implementar, depurar, generar pruebas, interpretar salidas y redactar. Las instrucciones exigieron cuatro experimentos, tracking, evidencia real y prohibición de inventar métricas. Se validó mediante Spark, tests de bordes, conteos exactos, hashes, conservación de filas, recarga de modelos y comprobación del procesamiento textual. El prompt original se conserva; la defensa debe explicar decisiones y límites, no solo reproducir código.

Fuentes

Pauta ProyectoIntegradorADBD2026; informe y notebook NYC311 de fase 1; ADBD3, ADBD4 y ADBD5; Lab3 de calidad, Lab4 de pipelines y MLflow, y Lab5 de embeddings. Tablas verificables: quality_by_year.csv, cohort_*.json, experiment_folds.csv, experiment_summary.csv, e4_vs_e1.csv, threshold_scenarios.csv, benchmark_summary.csv, test_subgroups.csv y mlflow_runs.csv.