NYC311
Streaming y gobernanza

Informe consolidado del Proyecto Integrador
Análisis de Big Data · Magíster en Data Science UDD

Dante Aguirre · Profesor Luis Castillo
1 de octubre de 2026

Decisión principal

La extensión con Kafka y Structured Streaming procesó el replay y verificó ventanas, atrasos y recuperación. El modelo batch se conserva como apoyo exploratorio con revisión humana: alerta el 79,27% de la prueba y presenta brechas territoriales que impiden recomendar una priorización automática sin validación adicional.

La pregunta de negocio es identificar al ingreso solicitudes con riesgo de atención prolongada respecto de su tipo de reclamo. El percentil 75 histórico de resolution_hours define una demora relativa; no representa un plazo contractual ni un SLA oficial. El informe conecta la exploración y preparación con el modelo, la extensión de streaming, los costos y los controles necesarios antes de operar.

Componente	Evidencia y alcance
Escala y continuidad	13.072.334 solicitudes de 2021–2024; se conservan los resultados y artefactos de las fases previas.
Modelo final	9.189.270 casos de entrenamiento y 3.365.506 de prueba; área PR 0,4092 y recall 0,8449.
Streaming real	7.269 solicitudes de un día y un evento de frontera; 125 ventanas; un atraso extremo descartado y uno leve aceptado.
Gobernanza	SPD, DI y errores por territorio/canal; trazabilidad y separación entre controles ejecutados y pendientes.
FinOps	Piloto de 8 GB: USD 55,80/mes de infraestructura con contingencia; capacidad cloud aún por medir.

El repositorio incluye notebook ejecutado, código, evidencias, modelo y tracking de fase 2. La demostración de streaming usa un día completo; no se presenta como una prueba del flujo de los cuatro años ni de capacidad máxima.

1 Datos y preparación acumulada

Fuente y escala

El snapshot NYC Open Data erm2-nwe9 se descargó el 11 de septiembre de 2026 según fase 1. Contiene 13.072.334 solicitudes únicas de 2021–2024 y 3.723.706.680 bytes de CSV seleccionados (3,72 GB decimales). Cumple la pauta por número de filas, no por superar 5 GB. Una actualización actual de la API no sustituye este snapshot sin versionarla.

Año	Solicitudes
2021	3.220.882
2022	3.169.960
2023	3.224.723
2024	3.456.769

Calidad y capas

Bronze conserva los archivos crudos y manifiestos; Silver tipa y particiona por año; Gold construye variables disponibles al ingreso y la etiqueta. Se auditaron 12.889.965 cierres. La cobertura de due_date, de aproximadamente 0,37%, no permite definir un SLA global. La demanda registrada mide acceso y propensión a reportar además de necesidad de servicio.

La zona America/New_York produce 25.428 duraciones negativas frente a 26.113 bajo America/Santiago en fase 1. La conciliación identifica 1.029.895 duraciones diferentes y una reducción neta de 685 negativas. Se excluyen los casos inválidos de la etiqueta y se preserva la evidencia de ambas procedencias; la corrección no borra el antecedente.

Etiqueta y prevención de fuga

Cada corte aprende el p75 aproximado por complaint_type con toda la historia cerrada antes del corte, accuracy 10.000 y mínimo de 100 casos por tipo. La etiqueta vale uno si la duración supera ese umbral. Los tipos sin soporte histórico reciben abstención. Cierre, estado, descripción de resolución y actualizaciones posteriores no son predictores.

El entrenamiento final usa 2021–2023 y la prueba 2024, con fecha de observación conservadora al inicio del 11 de septiembre de 2026. El snapshot no conserva versiones históricas de los atributos; esta limitación impide garantizar que todos representen exactamente el estado al ingreso. Las solicitudes abiertas o inválidas quedan fuera de la evaluación supervisada.

La trazabilidad se apoya en hashes de crudos, configuración, controles de cohortes y MLflow. No se descargaron nuevas solicitudes ni se modificó el modelo durante fase 3.

2 Modelo y desempeño predictivo

El desarrollo comparó cuatro familias con 18 ajustes: nueve candidatos evaluados en dos cortes temporales, 2021→2022 y 2021–2022→2023. Se utilizó una muestra determinista del 0,2% para desarrollar, pero los umbrales se calcularon con historia completa. El ajuste final usa el 100% de los 9.189.270 casos elegibles.

Familia	Área PR media de validación
E1 referencia	0,303823
E2 mejor candidato	0,304307
E3 GBT seleccionado	0,330243
E4 MiniLM congelado	0,315685

La selección por área PR media favoreció E3_3: GBT con profundidad 5, 20 iteraciones y umbral 0,2, fijado con validación. E4 usa embeddings de 384 dimensiones con revisión de encoder fijada; mejora 0,011862 respecto de E1, pero no supera al GBT. No se usó 2024 para elegir la familia, configuración o umbral.

Prueba completa 2024	Resultado
Casos / positivos	3.365.506 / 957.822
TP / FP	809.219 / 1.858.782
FN / TN	148.603 / 548.902
Área PR / ROC	0,4092 / 0,6174
Precisión / recall / F1	0,3033 / 0,8449 / 0,4464
Fracción alertada / prevalencia	79,27% / 28,46%
Ajuste final / inferencia materializada	2.115,85 s / 10,38 s

Implicación operativa

La detección de positivos es alta, pero 2.668.001 solicitudes quedarían seleccionadas para revisión. La precisión del 30,33% y la carga del 79,27% no demuestran una priorización eficiente con capacidad limitada. Se requiere valorar falsos positivos, falsos negativos y recursos humanos antes de automatizar cualquier asignación.

Los intentos iniciales se interrumpieron por falta de disco. Un modelo provisional del 5% observó la prueba antes del reintento completo; este conservó la selección y el umbral previos, sin retuning con 2024. Por ello no se describe el test como observado una única vez. La recarga registrada del modelo final tuvo error máximo de predicción 0,0; fase 3 no repite el entrenamiento.

3 Consultas reales y decisión de motor

Se incorporó la observación del profesor: medir monthly_borough y agency_window para decidir sobre el proceso completo. La primera resume demanda por mes y territorio; la segunda utiliza ventanas por agencia. Se ejecutaron sobre toda Silver con resultado materializado, calentamiento y tres repeticiones, driver de 2 GB, cuatro particiones SQL y AQE. No hubo persistencia Spark; la caché del sistema operativo no se controló.

Consulta	local 1 mediana s	local 2 mediana s
monthly_borough	4,742	3,081
agency_window	13,994	9,151
Par de consultas por repetición	18,905	12,034

La razón entre medianas del par es 1,571. Los conteos y rankings coinciden; dos medianas aproximadas y cuatro diferencias derivadas varían hasta 0,1 h. Son diferencias toleradas y documentadas, no igualdad exacta de toda la salida. Los ensayos comparan paralelismo local de Spark; no son una nueva comparación Spark versus DuckDB/Polars sobre estas consultas.

En fase 1, DuckDB fue más rápido en agregaciones simples que cabían en el Mac. El PDF y el notebook de esa fase contienen series de tiempos diferentes; no se mezclan aquí como evidencia homogénea. Spark se mantiene por continuidad con preparación, MLlib y Structured Streaming, no por demostrar superioridad en consultas locales. Una elección productiva intermotor todavía requeriría medir las consultas reales con la misma lógica en ambos motores.

Dónde se concentra el tiempo

Etapa medida	Segundos
Preparación	253,69
Par de consultas local 2	12,03
Ajuste final	2.115,85
Inferencia materializada	10,38
Suma orientativa	2.391,96 = 39,87 min

El ajuste representa el 88,5% de esa suma. Son mediciones de corridas distintas y excluyen tuning, arranques, evaluación, guardado y entregables: no equivalen al tiempo de pared completo del proyecto. La extensión de streaming se mide por separado; no se suma a una operación batch que tendría otra frecuencia.

La decisión es conservar local[2] para el prototipo y medir un piloto antes de escalar. No se extrapola aceleración lineal ni se justifica un clúster distribuido con un ensayo de uno y dos núcleos.

4 Arquitectura y prueba de streaming

La extensión usa Kafka 3.7.1 y Structured Streaming de Spark 3.5.4. El flujo es Silver → replay JSONL → Kafka → agregación por ventana y borough → Parquet append con checkpoint. El broker tiene tres particiones, una réplica y retención de 24 h; Spark usa local[2], driver 2 GB y cuatro particiones SQL.

Decisión	Implementación
Contrato mínimo	event_id, event_ts con zona, borough y campos de auditoría de emisión. Sin dirección, coordenadas ni texto libre en Kafka.
Ventana	Una hora por borough, sobre tiempo del evento.
Atrasos	Watermark de dos horas; la salida append publica ventanas cerradas.
Durabilidad del ensayo	Offsets y estado en checkpoint; resultados Parquet y métricas por microbatch.
Seguridad y disponibilidad	Solo localhost; sin TLS/SASL ni réplica redundante. Configuración académica, no productiva.

Replay desde el dataset propio

Se incluyen las 7.269 solicitudes creadas el 1 de enero de 2024, sin muestreo dentro del día. Se conservan sus timestamps reales y se modifica solo el orden de emisión: una solicitud de las 06 h se emite a las 07 h y una de las 00 h a las 08 h. Son casos controlados de atraso leve y extremo, no una estimación de atrasos reales.

Una solicitud real del 2 de enero a partir de las 03 h permite avanzar el watermark y cerrar todo el día previo. En total se envían 7.270 mensajes. El reloj de pared por sí solo no finaliza la última ventana: se necesita avance del tiempo de evento. El archivo de entrada y su hash quedan incluidos para repetir la prueba sin descargar los cuatro años.

Recuperación y límites

A mitad del replay se detiene y reinicia la consulta con el mismo checkpoint, sin emitir mensajes nuevos durante la verificación. El resultado conserva 52 filas antes y después, sin duplicación. La prueba cubre continuidad de offsets confirmados en este flujo; no deduplica el mismo ID si se republica con un offset nuevo.

Cada reproducción crea un tópico y salida nuevos. El checkpoint archivado contiene rutas y offsets del broker original y no sirve para reiniciar contra otro broker. Antes de operar se requieren contrato de identificadores, deduplicación explícita, manejo de entradas inválidas y pruebas adicionales de falla.

5 Resultados del replay y rendimiento

Control	Resultado observado
Mensajes enviados / consumidos	7.270 / 7.270
Solicitudes del día retenidas	7.268 de 7.269
Atrasos leve / extremo	Uno aceptado / uno descartado por watermark
Ventanas por territorio	125; igualdad exacta con el oráculo batch
Reinicio con checkpoint	52 filas antes y después; cero duplicadas
Arranque Spark / replay	2,46 s / 77,63 s
Tasa efectiva regulada	93,64 mensajes/s; no es capacidad máxima

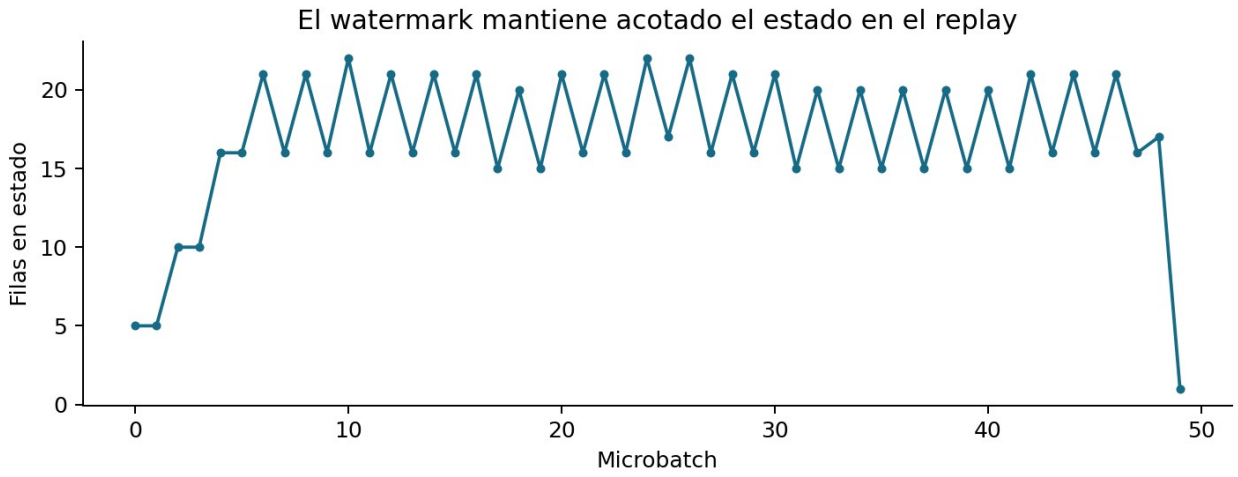


Figura 1. Estado observado por microbatch. Máximo 22 filas; una al terminar, correspondiente al evento de frontera. Fuente: stream_run/evidence/progress.json.

El máximo muestreado de RSS Python + Spark fue 768.786.432 bytes (733,17 MiB). Excluye el broker Kafka independiente y no mide memoria física exclusiva. El productor espera la finalización de cada bloque; por eso la tasa efectiva no permite dimensionar una carga de producción ni inferir saturación.

Alertas de volumen

Sobre las ventanas cerradas se aplica una regla: solicitudes mayores que dos veces la línea base y al menos 20. La base es el promedio de las tasas horarias mensuales de 2023 por borough; no modela hora, día de semana ni estacionalidad. El cálculo ocurre después del replay sobre Parquet, no en un sink continuo.

Se obtuvieron cero ventanas alertadas. No se altera la regla ni se inyectan picos para obtener alertas. Un control artificial separado verifica los bordes de la regla. Estas alertas de volumen son distintas de las alertas de demora del clasificador, que no se ejecuta dentro del stream.

6 Brechas de selección y detección

Se evalúa el modelo final sobre los 3.365.506 casos de prueba mediante conteos completos de TP, FP, FN y TN. Cada agrupación reconcilia exactamente con los totales globales. El resultado favorable se define como selección para revisión humana, un beneficio hipotético condicionado a capacidad de atención. No se ha demostrado ese beneficio.

SPD es la diferencia de tasas de selección y DI su razón respecto del grupo de mayor tamaño: Brooklyn para territorio y ONLINE para canal. TPR mide detección entre positivos; FPR mide falsos positivos entre negativos. La referencia se fija por tamaño, sin buscar la mayor disparidad. DI menor a 0,8 es una señal diagnóstica de clase, no un dictamen legal.

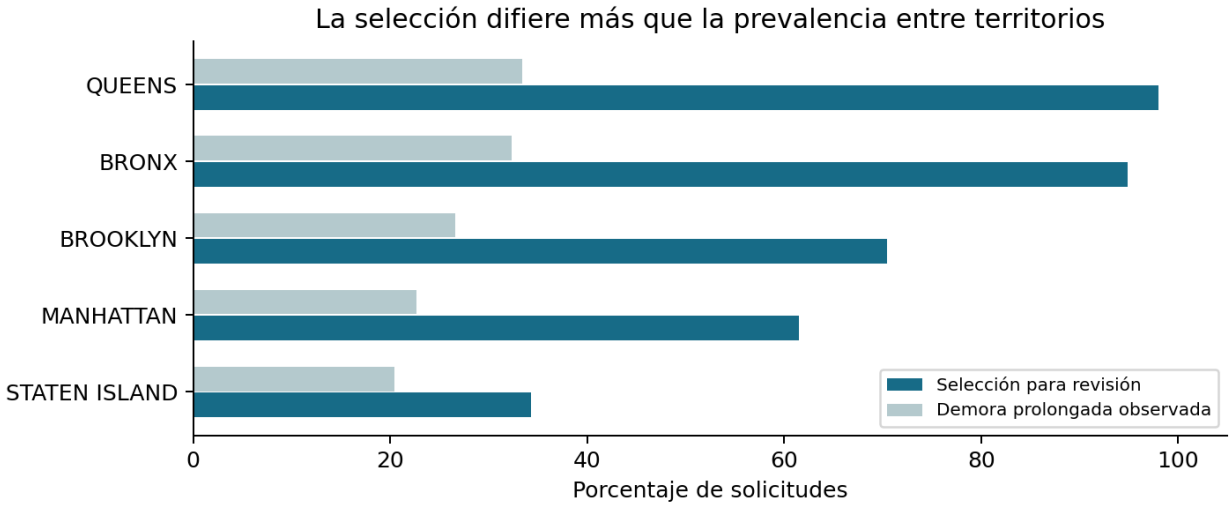


Figura 2. Tasas completas del test 2024. Los desconocidos se conservan en las tablas de auditoría y se excluyen de este gráfico de cinco territorios.

Territorio	Selección	SPD pp	DI	TPR
Brooklyn	70,43%	0,00	1,000	70,52%
Staten Island	34,34%	−36,09	0,488	41,29%
Manhattan	61,52%	−8,91	0,873	68,75%
Bronx	94,91%	+24,47	1,347	98,55%
Queens	98,01%	+27,57	1,392	99,24%

Staten Island presenta una diferencia de detección de −29,23 pp frente a Brooklyn. Queens y Bronx quedan casi totalmente seleccionados. La magnitud de la brecha de selección supera la de prevalencia en todos los territorios comparados con la referencia, con tolerancia descriptiva de 2 pp. La mezcla de reclamos y sus umbrales puede explicar parte de la diferencia; no se infiere causalidad.

7 Interpretación y controles de equidad

Canales y grupos pequeños

Canal	N	SPD pp vs ONLINE	DI
ONLINE referencia	1.348.190	0,00	1,000
PHONE	1.043.968	+10,87	1,144
MOBILE	713.069	−3,21	0,957
UNKNOWN	260.258	+16,79	1,223
OTHER	21	Sin interpretación	Sin interpretación

PHONE tiene una brecha TPR de +7,40 pp y MOBILE de −0,23 pp frente a ONLINE. Los desconocidos se mantienen separados. OTHER no admite interpretación operativa por su volumen; los cálculos permanecen en el CSV de auditoría con su marca de exclusión. Las brechas son descriptivas del snapshot, no intervalos de desempeño futuro.

Qué no demuestra esta auditoría

Borough y canal son dimensiones operativas, no atributos protegidos asignados a personas. No se infiere raza, sexo ni nivel socioeconómico individual a partir del territorio. Faltan esos atributos y cruces individuales para una auditoría demográfica e interseccional, por lo que no se certifica equidad respecto de grupos protegidos.

La evaluación incluye solicitudes cerradas y con umbral histórico disponible. El acceso para reportar, la mezcla de tipos, la censura de casos abiertos y la capacidad institucional afectan las etiquetas y las comparaciones. Una tasa de selección mayor tampoco garantiza mejor servicio cuando la capacidad es limitada.

Medidas propuestas antes de usar el modelo

Acción pendiente	Criterio de validación
Revisar errores por tipo y territorio	Separar mezcla de casos de errores del modelo usando datos de desarrollo y una validación temporal futura.
Ajustar objetivo operativo	Definir costo de errores y capacidad de revisión; evaluar precisión y recall al presupuesto de alertas disponible.
Evaluar mitigaciones	Comparar alternativas con el mismo protocolo y auditoría de beneficios; no escogerlas con el test 2024.
Supervisión humana	Registrar decisión final, motivo y posibilidad de revisión; evitar asignaciones automáticas sin evaluación de impacto.

Se mantiene el modelo de fase 2 para asegurar comparabilidad. No se alteraron umbrales por grupo ni se entrenó una mitigación en esta entrega. La auditoría identifica dónde investigar; no presenta una corrección no ejecutada como un resultado.

8 Costos mensuales y escalamiento

La estimación usa precios públicos de AWS Lightsail Linux con IPv4, consultados el 1 de octubre de 2026 [3–4]. Se planifica una VM continua en us-east-1, sujeto a disponibilidad y cuotas. No se contrataron recursos; los tiempos del Mac no garantizan el desempeño de esta VM.

Concepto USD por mes	8 GB 2 vCPU	16 GB 4 vCPU
VM con 160 / 320 GB de disco	44,00	84,00
50 GB retenidos en snapshots a 0,05	2,50	2,50
Infraestructura base	46,50	86,50
Presupuesto con 20% de contingencia	55,80	103,80
Trabajo supuesto 2 h × USD 20	40,00	40,00
Total con contingencia y trabajo	95,80	143,80

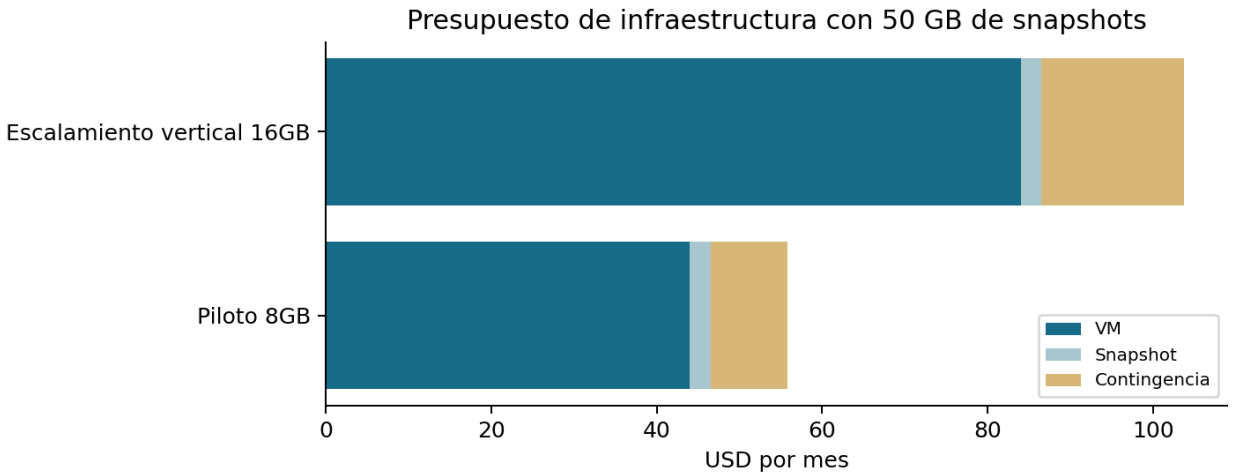


Figura 3. Presupuesto mensual de infraestructura. El trabajo humano supuesto se muestra por separado en la tabla. No corresponde a una factura cloud observada.

Los 50 GB representan almacenamiento de snapshots retenidos, no 50 GB nuevos cada día. Con 20–100 GB, el presupuesto de infraestructura del piloto varía entre USD 54,00 y 58,80 al mes. La transferencia se supone dentro de la cuota y los logs dentro del disco incluido. Se excluyen impuestos, sobreconsumos, observabilidad administrada, alta disponibilidad y operación de cumplimiento.

La VM aloja Kafka y Spark; entrenamiento y streaming se programarían separados para evitar competencia. Se recomienda iniciar con 8 GB, medir memoria total y atraso, y considerar 16 GB solo si la presión persiste. El replay regulado no prueba capacidad máxima. Una VM aprovisionada no se prorratea por minutos activos de Spark; detenerla no equivale a eliminar su cargo.

9 Gobernanza y uso responsable

Los datos son públicos, pero un identificador de solicitud, timestamp y territorio pueden vincularse a la fuente. La minimización del stream reduce exposición; no constituye anonimización irreversible. El acceso al crudo y a copias del proyecto debe limitarse a la finalidad académica y a sus condiciones de uso.

Control	Estado y alcance
Calidad y procedencia	Ejecutado: hashes, unicidad, cohortes, exclusiones y conciliación de zona horaria.
Trazabilidad del modelo	Ejecutado: parámetros, métricas, modelo, encoder, MLflow y decisión conservados.
Trazabilidad del stream	Ejecutado: contrato mínimo, checkpoint, progreso, tiempos y contraste batch.
Retención	Kafka configurado a 24 h. Política y eliminación de copias académicas y snapshots pendientes.
Seguridad de operación	Pendiente: identidades, permisos, cifrado, monitoreo y recuperación probada fuera de localhost.
Responsabilidad y derechos	Pendiente: responsable institucional, base jurídica, evaluación de impacto, canal de reclamos y revisión humana.

Marco normativo con fecha de corte

Al 1 de octubre de 2026, la Ley 21.719 tiene vigencia diferida al 1 de diciembre de 2026; la Ley 19.628 continúa como referencia vigente hasta la entrada del nuevo régimen [5]. Los controles se plantean como preparación y requieren revisión institucional. No se trata una propuesta legislativa citada en clase como una modificación ya vigente.

La aplicabilidad del GDPR debe evaluarse según su ámbito material y territorial; no surge automáticamente por usar datos NYC311. Minimización, limitación de conservación, seguridad y revisión de decisiones con efectos relevantes orientan el diseño [6]. No se certifica cumplimiento jurídico ni se autoriza una operación real a partir de este ejercicio.

Declaración de IA generativa

Se utilizó Codex/OpenAI para inspeccionar materiales, proponer y escribir código, ejecutar controles y redactar notebook e informe. Prompt literal de fase 3: “ahora tenemos que hacer la fase 3, según lo que ya hicimos de fase 1 y fase 2, tienes el detalle en el pdf sobre proyecto integrador”. Las fases previas conservan sus declaraciones; no se reconstruye una transcripción exhaustiva de prompts no registrada.

La validación computacional incluye Kafka real, oráculo batch independiente, hashes, reconciliación de confusión, recomputación de SPD/DI y costos, ejecución del notebook y revisión de páginas. Estos controles no reemplazan la revisión académica del autor ni la validación jurídica de una futura operación.

10 Reproducción y fuentes

El repositorio ofrece dos rutas. Para leer y verificar resultados, ejecutar el notebook en modo evidencia, sin Kafka ni reentrenamiento. Para reconstruir, seguir README.md: preparar los CSV de hashes fijados, ejecutar las etapas de phase2 y reconstruir el replay antes de iniciar Kafka. Se requiere Java 17, entorno Python compatible y almacenamiento local fuera de iCloud.

Ruta o artefacto	Función
phase2/run.sh y configuraciones	Crudo → preparación → tuning → benchmark → final → exportación. Modelo y MLflow históricos incluidos.
build_inputs.py	Silver → todas las solicitudes del día y evento de frontera; baseline histórica 2023.
setup_kafka.py y run_demo.sh	Broker local y conectores; nueva ejecución de streaming y auditorías.
streaming.py	Ventanas, watermark, recuperación y oráculo batch.
fairness_finops.py	Reconciliación completa, brechas y escenarios mensuales.
evidence y stream_run/evidence	Manifiestos, fuentes, tablas, métricas y trazas inspeccionables.

Los CSV originales y Silver no se duplican en el ZIP. El replay mínimo, modelo, encoder y evidencias sí se incluyen. La fase 3 ejecutó Kafka y los análisis nuevos; conserva el entrenamiento ya ejecutado de fase 2. Reconstruir desde crudos requiere más tiempo y espacio que abrir el notebook. Las instrucciones distinguen ambos alcances.

Fuentes

[1] Dataset NYC Open Data https://data.cityofnewyork.us/d/erm2-nwe9

[2] Spark Structured Streaming https://spark.apache.org/docs/3.5.6/structured-streaming-programming-guide.html

[3] Planes Lightsail https://docs.aws.amazon.com/lightsail/latest/userguide/amazon-lightsail-bundles.html

[4] Precios y snapshots https://aws.amazon.com/lightsail/pricing/

[5] Ley 21.719 BCN https://bcn.cl/gJo3hf

[6] GDPR EUR Lex https://eur-lex.europa.eu/eli/reg/2016/679/oj

Consulta externa: 1 de octubre de 2026. [2] se usa para semántica; la ejecución está fijada en Spark 3.5.4. Pauta Proyecto Integrador ADBD 2026, ADBD6–7 y Lab7 sustentan los requisitos. FUENTES.md amplía referencias y fechas. Las cifras restantes provienen de las ejecuciones y archivos adjuntos de fases 1–3.